



Universidad de Guadalajara

Centro Universitario de Ciencias Exactas e Ingenierías

CICLO ESCOLAR: 2025-B

Materia: Análisis genómico y proteómico

Clave: V0742 NRC: 225407 Sección: D01

Mtro. MOISES SOTELO RODRIGUEZ

-----**Carlos Andrei Saucedo Aguilar**-----

Código: 220285443

Entregable 1

Resumen de obtención de datos

Fuente exacta y versión del dataset

Los datos utilizados provienen de ClinVar, una base de datos pública mantenida por el National Center for Biotechnology Information (NCBI).

Para el proyecto use la versión más reciente:

NCBI ClinVar FTP — Variants Summary:

https://ftp.ncbi.nlm.nih.gov/pub/clinvar/tab_delimited/variant_summary.txt.gz

Fecha de acceso: enero 2025.

Esta tabla es usada para poder entender mejor el problema biológico que andamos usando ya que pues no es muy difícil de usar xd.

Descripción del proceso de descarga/acceso

1. Se accedió al FTP público de ClinVar.
2. Se descargó el archivo comprimido variant_summary.txt.gz.
3. Se descomprime usando pues el RAR lo que nos dejó un archivo de 3.42GB.
4. El archivo resultante (variant_summary.txt) fue cargado a Python usando `pandas.read_csv()` con el delimitador tabular.

ClinVar es de acceso abierto así que no hay problemas por accesos.

Características básicas del dataset obtenido

El archivo contiene:

- Más de 2 millones de variantes registradas.
- Columnas principales:
 - GeneSymbol
 - Chromosome
 - Start, Stop
 - Type (missense, deletion, insertion, etc.)
 - ClinicalSignificance
 - Protein_change
 - ReviewStatus

El dataset es de tipo tabular con anotaciones clínicas y funcionales.

Problemas encontrados y cómo se resolvieron

Problema	Solución
Alto volumen de datos hacía lento el procesamiento inicial	Se filtró por variantes con clasificación clara (solo Pathogenic y Benign).
Presencia de valores nulos en columnas como Protein_change	Se eliminaron o imputaron dependiendo de la relevancia de la característica.
Etiquetas de clasificación inconsistentes (“Pathogenic/Likely pathogenic”)	Se normalizaron dividiéndolas en categorías binarias para el modelo.
Dataset muy desbalanceado: más variantes benignas que patogénicas	Se planteó el uso de balanceo mediante SMOTE o pesos de clase.

2. Análisis exploratorio

1.1 Dimensiones del dataset

Tras cargar el archivo original:

- Filas totales: 8,359,346
- Columnas totales: 43

Estas dimensiones confirman que se trata de un dataset masivo, adecuado para análisis de variantes, anotación clínica y que google me dijo que eran 2 millones pero ya son mas xd.

1.2 Tipos de datos

El dataset contiene variables categóricas, numéricas y textuales. Las principales categorías incluyen:

Columna	Tipo	Descripción
Chromosome	categorico	Cromosoma 1-22, X, Y
Start	numérico entero	Posición genómica inicial
ReferenceAllele	texto	Alelo de referencia
AlternateAllele	texto	Alelo alternativo
Type	categorico	Tipo de variante (SNV, deletion, insertion, etc.)
ClinicalSignificance	categorico	Patogénico, Benigno, etc.

ReviewStatus	categorico	Nivel de evidencia
RS# (dbSNP)	numérico	Identificador dbSNP
GeneSymbol	categorico	Gen asociado

1.3 Valores faltantes

Un análisis preliminar muestra:

- Algunas columnas tienen valores vacíos (por ejemplo: PhenotypeList, Cytogenetic).
- Las columnas utilizadas para el modelo (Chromosome, Start, Alleles, Type, GeneSymbol, ClinicalSignificance) no contienen valores faltantes críticos.
- El dataset filtrado es consistente y no necesita imputación para estas variables.

1.4 Estadísticas descriptivas básicas

Sobre el subconjunto utilizado (813,432 variantes filtradas):

- Benign: 425,254
 - Pathogenic: 388,178
- osea clases relativamente balanceadas.

Distribución general:

- Promedio de posición (Start): entre ~10 millones y 60 millones por cromosoma.
- Tipos de variantes más comunes:
SNV > deletion > insertion (según gráfico generado).

Las variantes están mayormente distribuidas en todos los cromosomas, con picos esperados en cromosomas grandes (1, 2, 7, o más.).

2. Análisis específico para variantes genómicas

2.1 Distribución de tipos de variantes

Se utiliza la columna Type.

Resultado observado:

- Predominan las SNV (Single Nucleotide Variant).
- Hay presencia notable de:
 - *deletion*

- *insertion*
- *delins*
- *duplication*

Interpretación:

Las SNV según yo representan la forma más común de variación genética, lo que encaja con la biología humana.

2.2 Balance de clases (Patogénico/Benigno)

Conteo:

- Benign: 425,254
- Pathogenic: 388,178

Interpretación:

El dataset está casi balanceado pero es ideal para entrenamiento del modelo que pienso usar.

2.3 Distribución por cromosoma

Los cromosomas con más variantes fueron: 1, 2, 7, 11 y 17 (en concordancia con su tamaño y densidad de genes).

El cromosoma Y tiene un número significativamente menor, esto si no lo sabia.

Interpretación:

La distribución se alinea con el contenido génico y la longitud física de los cromosomas: cromosomas grandes tienen más variantes reportadas

2.4 Análisis por gen


En los datos, el gen más frecuente en las primeras filas es AP5Z1 (Cromosoma 7). A nivel global, el dataset contiene miles de genes, pero muchos tienen muy pocas variantes anotadas.

Interpretación:


Aquí si le pregunte a ChatGPT, esto es característico de ClinVar: la anotación depende de reportes de laboratorios, no del tamaño del gen.

2.5 Distribución de variantes por región genómica


Con la columna Chromosome y Start puede generarse un mapa de densidad. Los datos muestran mayor agregación en regiones génicas, pero no se graficó todavía.



Las dos clases están relativamente balanceadas por lo que a mi parecer esta excelente



Aquí se observa que las snv son el tipo más frecuente de manera super obvia y que las deletions e insertions son algo comunes



Los cromosomas largos o sea los 1,2 y 7 tienen más variantes y el cromosoma Y es la que tiene menos variantes, lo que según yo es parecida al genoma humano

Conclusiones del EDA

1. El dataset es grande, robusto y bien anotado, sin valores faltantes relevantes en las columnas clave.
2. La clase clínica está balanceada, por lo que entrenar algún modelo sería fácil.
3. Las SNV son el tipo dominante de variante, como ocurre naturalmente.
4. La distribución por cromosoma coincide con las expectativas biológicas.
5. Los datos están listos para preprocesamiento y modelado, incluyendo:
 - One-hot encoding para variables categóricas.
 - Normalización de posiciones genómicas.

Pasos de limpieza realizados

1.1 Manejo de valores faltantes

Se evaluaron los valores faltantes en todas las columnas. Las variables seleccionadas para el análisis y el modelado fueron:

- Chromosome
- Start
- ReferenceAllele
- AlternateAllele
- Type
- ClinicalSignificance
- ReviewStatus
- RS# (dbSNP)
- GeneSymbol

Estas columnas no contenían valores faltantes críticos, por lo que:

- No fue necesaria imputación.
- No se eliminaron columnas completas.
- Solo se descartaron filas cuando el valor en ClinicalSignificance no estaba definido o no coincidía con las clases objetivo.

1.2 Eliminación de duplicados

Se revisó si existían duplicados en el subset seleccionado. En datasets de ClinVar, duplicados reales son raros porque cada fila normalmente corresponde a un registro único de variante.

- Se aplicó `df_subset.drop_duplicates()`.
- El número de duplicados encontrados fue mínimo y no alteró el tamaño final de manera relevante.

1.3 Filtrado de datos de baja calidad

El filtro principal fue sobre la etiqueta clínica:

```
df_clean = df_subset[df_subset["ClinicalSignificance"].isin(["Pathogenic", "Benign"])]
```

Esto permitió:

- Mantener sólo variantes con anotación clínica clara y binaria.
- Eliminar entradas ambiguas como:
 - “Likely benign”
 - “Likely pathogenic”
 - “Uncertain significance”
 - “Conflicting interpretations”
 - “Not provided”

Este paso redujo el dataset de 8,359,346 → 813,432 filas, reteniendo solo muestras con evidencia sólida.

Transformaciones aplicadas

2.1 Cambios de formato

No fueron necesarios cambios de formato complejos porque:

- Chromosome se conservó como texto (importante para los cromosomas X e Y).
- Start se mantuvo entero.
- Los Alelos se mantuvieron como strings.

- RS# Se utilizó como numérico, pero sin procesamiento adicional.

2.2 Extracción de features

Se seleccionaron solo las columnas relevantes para el modelo, eliminando ruido:

```
cols = [  
    "Chromosome", "Start", "ReferenceAllele", "AlternateAllele",  
    "Type", "ClinicalSignificance", "ReviewStatus",  
    "RS# (dbSNP)", "GeneSymbol"  
]  
  
df_subset = df[cols].copy()
```

Esto eliminó:

- Todas las columnas relacionadas con anotaciones clínicas secundarias (Oncogenicity, SomaticClinicalImpact, etc.)
- IDs irrelevantes para clasificación
- Información fenotípica incompleta

2.3 Codificación de labels

Se seleccionaron únicamente dos clases:

- Benign -> 0
- Pathogenic -> 1

(La codificación binaria se aplicará más adelante; aquí sólo se construyó el dataset filtrado.)

2.4 Normalización / estandarización

No se aplicó normalización en esta etapa porque:

- El modelo aún no ha sido definido (árboles, regresión, redes neuronales, etc.)
- La variable numérica principal (Start) puede normalizarse posteriormente dependiendo del algoritmo seleccionado.

Preparación del subset de trabajo

3.1 Subset para pruebas iniciales

Dado que el tamaño del dataset filtrado es de 813,432 variantes, se considera adecuado para un primer modelo completo. Sin embargo, para pruebas rápidas para ir probando el modelo se puede usar:

- Un subset aleatorio de 50,000 a 100,000 filas
- Método: muestreo aleatorio estratificado en ClinicalSignificance

Esto no lo he ejecutado pero es la idea:

```
df_sample = df_clean.groupby("ClinicalSignificance").sample(n=50000, random_state=42)
```

Splits de entrenamiento / validación / prueba

Se aplicarán en la fase de modelado:

- 70% entrenamiento
- 15% validación
- 15% prueba
- Estratificados por clase

```
train, temp = train_test_split(df_clean, test_size=0.30,  
stratify=df_clean["ClinicalSignificance"])
```

```
val, test = train_test_split(temp, test_size=0.50, stratify=temp["ClinicalSignificance"])
```

Estadísticas antes y después del preprocesamiento

Etapas	Filas	Columnas
Dataset original	8,359,346	43
Subset de columnas	8,359,346	9
Filtrado de clases (Benign/Pathogenic)	813,432	9

Distribución final:

- Benign: 425,254
- Pathogenic: 388,178

La relación de clases quedó en aproximadamente 52% / 48%

Justificación de las decisiones tomadas

Acción	Justificación
Selección de 9 columnas	Reducir ruido y memoria; solo conservar variables útiles para modelado.
Filtrado por clase	Evitar ambigüedad; mantener claridad en clasificación binaria
No imputar valores	Los campos clave no contienen NaN relevantes
No normalizar aún	Según para el RandomForest no es necesario pero queda pendiente
Posible subset estratificado	Agilizar ciclos de prueba sin sesgo de clase.

Reflexiones y Ajustes

1. Adecuación de los datos al proyecto original

En general, el dataset obtenido es adecuado para el proyecto, se cuenta con:

- Un número grande de variantes (813,432)
- Dos clases bien representadas
- Variables biológicamente relevantes (cromosoma, alelos, tipo de variante, posición genómica, gen, etc.)

Esto permite entrenar modelos tanto simples (regresiones, árboles) como complejos (random forest, XGBoost, redes neuronales).

Sin embargo, el dataset no es directamente utilizable para proyectos que requieren:

- Información de expresión génica
- Secuencias completas flanqueantes
- Datos estructurales de proteínas
- Métricas biofísicas
- Condiciones de tejido o contexto celular

Por lo tanto, es limitado para tareas de predicción funcional más avanzadas, pero si es necesario cambiar de dataset lo haré.

2. Ajustes necesarios a la propuesta original

Durante el análisis exploratorio surgieron elementos que justifican ajustes a la propuesta inicial:

Ajuste 1: Mejorar la clasificación de datos

Las columnas disponibles son informativas, pero insuficientes para modelar biología compleja. Se requerirá:

- Convertir los alelos en representaciones numéricas
- Extraer longitud de la variante
- Calcular indicadores como:
 - tipo de cambio (transición/transversión)
 - cambio de frameshift vs missense vs stop-gain
 - información del gen (tamaño, intolerancia mutacional)

Ajuste 2: Evaluar balance de clases por tipo de variante

Aunque "Benign" y "Pathogenic" están balanceadas, algunos tipos de variantes (Type) no lo están.

Esto impactará el modelado y puede requerir:

- Rebalanceo por tipo de mutación
- Pesos de clase
- Modelos específicos por categoría

Ajuste 3: Filtrar variantes dudosas

La columna ReviewStatus aún contiene variantes con:

- Una sola sumisión
- Revisión limitada
- Evidencia clínica insuficiente

Se podrían eliminar para mejorar la confiabilidad.

3. Desafíos encontrados

Desafío 1: Tamaño del dataset

El archivo original tiene más de 8.3 millones de filas, lo que causa:

- Carga lenta

- Alto uso de memoria
- Necesidad de filtros estrictos

Este desafío no fue anticipado completamente y tuve que trabajar con subsets pero x.

Desafío 2: Inconsistencia en categorías clínicas

La etiqueta ClinicalSignificance tiene más de 20 categorías posibles.

Al inicio no era evidente cuántas eran irrelevantes o ambiguas (“Likely”, “Conflicting”, etc.).

Esto requirió:

- Analizar las categorías una por una
- Decidir un esquema de clasificación binaria

Desafío 3: Datos genómicos heterogéneos

El dataset mezcla:

- Variantes germinales
- Variantes somáticas
- Indels
- SNVs
- Eventos estructurales
- Anotaciones relacionadas con cáncer

Esto obliga a normalizar criterios para evitar introducir ruido clínico innecesario.

4. Aprendizajes clave para el modelado

Durante el EDA y preprocesamiento se obtuvieron insights importantes que guiarán el modelado:

Aprendizaje 1: Algunas features tienen bajo poder explicativo

Por ejemplo:

- RS# (dbSNP) es solo un identificador, no una medida biológica
- ReviewStatus depende del proceso de curación, no de la variante
- Chromosome por sí solo aporta poca información para clasificar benigno/patogénico

Será necesario:

- Generar features derivadas
- Agregar información externa si se busca mayor precisión

Aprendizaje 2: El tipo de variante es un predictor fuerte

Los resultados preliminares muestran grandes diferencias en frecuencia entre:

- SNVs
- Deleciones
- Inserciones
- Indels

Esto indica que el modelo debería:

- Incluir "Type" como feature categórica principal
- Considerar algoritmos que manejan bien variables discretas

Aprendizaje 3: Existen patrones por cromosoma

La distribución no es uniforme:

- Cromosomas grandes tienen más variantes
- El cromosoma X tiene patrones distintos por efecto de hemicigosidad

Esto puede llevar a:

- Modelos con interacciones entre posición + tipo de variante
- Features basadas en densidad de mutación

Aprendizaje 4: El dataset filtrado tiene buena calidad

Con 813 mil variantes y sin problemas severos de valores faltantes, se puede avanzar a la siguiente fase sin necesidad de más depuración.

Por último, no le trabajado tanto en el proyecto ya que estuve trabajando en otros proyectos de los cuales tarde mucho más entiendame profe xd